Prozesserzeugung & Synchronisation

FH Münster

Probevorlesung

Dr.-Ing. Darius Malysiak

Inhalt

- I. Motivation / Lernziel
- II. Prozesserzeugung
 - 1. Was sind Prozesse?
 - 2. Wie werden Prozesse erzeugt (Linux)?
- III. Synchronisation von Prozessen
 - 1. Warum überhaupt Synchronisieren?
 - 2. Möglichkeiten zur Synchronisation
- IV. Gemeinsame Übung

I. Motivation / Lernziel

Lernziele:

- Vermittlung der Begrifflichkeiten zu Prozessen und Synchronisationsproblemen.
- Verständnis vermitteln zur Kommunikation zwischen Prozessen.
 - Verständnis vermitteln zu daraus resultierenden Problemen und deren Lösung.
- Erklärung der Zusammenhänge zwischen Theorie und Implementierung in Linux.
- Schaffen einer Basis für das Selbststudium.

1. Was sind Prozesse?

Allgemein gesprochen führt ein Computer System spezifische Aufgaben aus:

- Ein Batch System (z.B. Mainframe) führt Jobs gesammelt aus:
 - Daten Transaktionen
 - Datenprüfungen
 - Daten Analysen
- Ein System mit Time-Sharing (z.B. Desktop Computer) führt Programme oder Tasks aus:
 - Anwenderprogramme
 - Dienste
 - Periodische Aufgaben

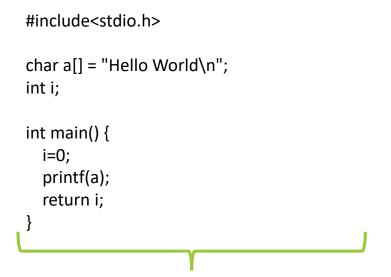
Jobs, Tasks, Programme müssen im Computer dargestellt werden.

Analogie aus der OOP: Klassen werden durch Objekte "zum Leben erweckt".

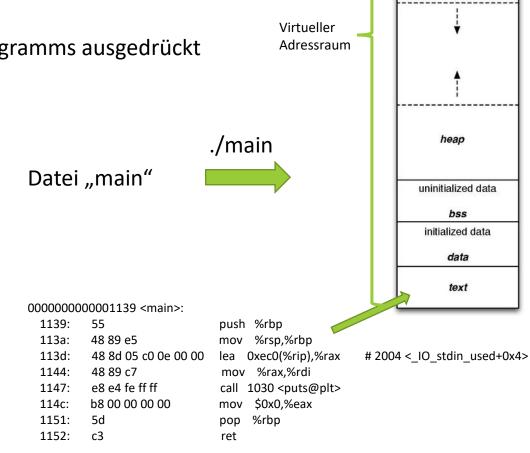
1. Was sind Prozesse?

Eine Aufgabe wird für den Computer in Form eines Programms ausgedrückt

Compiler



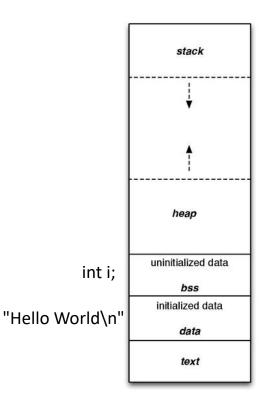
Programmcode / Programm



Prozess

stack

1. Was sind Prozesse?



- Stack: Hier werden lokale Funktionsvariablen / Funktionsdaten abgelegt, dazu noch Verwaltungsdaten wie z.B. die Rücksprungadresse. Beim Verlassen einer Funktion werden diese Daten entfernt.
- Heap: Hier werden globale Funktionsdaten oder größere Datenmengen abgelegt. Der Speicher wird nicht automatisch verwaltet und kann Fragmentierung entwickeln.
- BSS: Hier werden globale / lokale statisch allokierte, jedoch nicht initialisierte Variablen abgelegt.
 Dieser Bereich wird zur Laufzeit mit ensprechenden Daten befüllt.
- DATA: Hier werden globale / lokale statisch allokierte Variablen abgelegt, welche bereits initialisiert sind. Dieser Bereich wird zur Laufzeit mit entsprechenden Daten befüllt, kann jedoch bereits in der ausführbaren Datei betrachtet werden.

2. Wie werden Prozesse erzeugt? (Linux)

Ein Prozess wird unter Linux erzeugt indem:

- Der aktuell laufende Prozess eine Kopie von sich erstellt. (Fork)
- 2. Das Betriebssystem die Kopie mit dem Inhalt des entsprechenden Programms befüllt. (Exec)

```
PIDAUSER
  1 root
                                     5248 S
                                                       3:47.86 /sbin/init
                                                                  /usr/lib/systemd/systemd-udevd
424 root
                                     3260 S
                                                       0:03.50
509 dbus
                                                                  /usr/bin/dbus-daemon --system --address=systemd: --nofork --
                                     2292 S
                                                       0:01.49
                                                                   /usr/lib/systemd/systemd-logind
511 root
                                                       0:00.99
                                     4104 S
613 root
                                                                   /usr/bin/dockerd -H fd://
632 root
                                                      10:18.93
                                                                   — /usr/bin/dockerd -H fd://
633 root
                                                  0.1 7:18.18
                     0 7242M 70576 17396 S
                                                                      /usr/bin/dockerd -H fd://
634 root
                                                       0:00.20
                                                                      /usr/bin/dockerd -H fd://
635 root
                                                  0.1 10:02.27
                                                                    — /usr/bin/dockerd -H fd://
636 root
                                                       0:00.00
                                                                      /usr/bin/dockerd -H fd://
637 root
                                                       0:00.00
                                                                      /usr/bin/dockerd -H fd://
638 root
                     0 7242M 70576 17396 S
                                                       0:00.39
                                                                     /usr/bin/dockerd -H fd://
639 root
                                                       0:00.26
                                                                      /usr/bin/dockerd -H fd://
640 root
                                                       0:00.23
                                                                      /usr/bin/dockerd -H fd://
641 root
                                                       0:00.01
                                                                    – /usr/bin/dockerd -H fd://
642 root
                                                                      /usr/bin/dockerd -H fd://
```

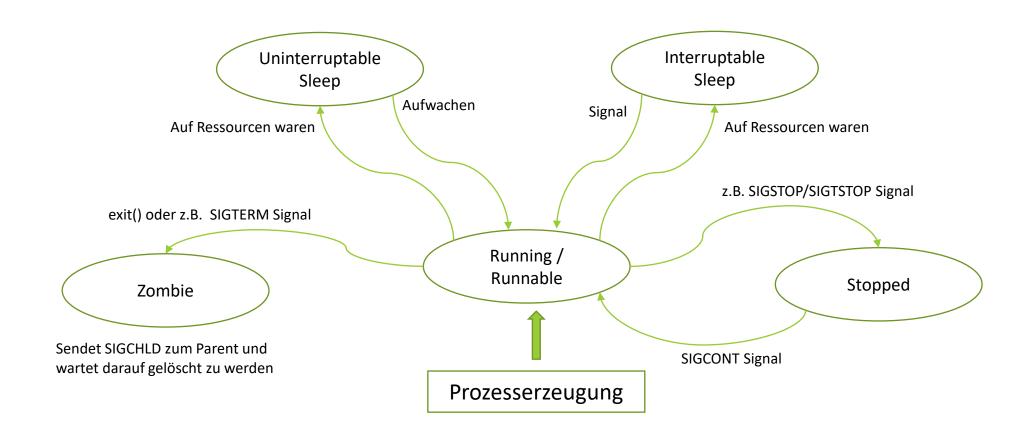
2. Wie werden Prozesse erzeugt? (Linux)

```
int main() {
  pid_t pid = fork();
  if (pid == -1) {
       printf("Failed to fork\n");
  else if (pid > 0) {
      int status;
      printf("Parent: waiting for child\n");
      waitpid(pid, &status, 0);
      printf("Parent: child finished work\n");
  else {
      printf("Child: sleeping for 5s\n");
      sleep(5);
      printf("Child: woke up\n");
  return 0;
```

- Mit ,getpid' wird die eigene ID (des Elternprozesses) abgefragt.
- Die Funktion ,fork' führt einen Fork und erzeugt eine Kopie von sich als Kind-Prozess.
- Der Elternprozess erhält seine ID zurück, der Kindprozess erhält ,0' zurück.

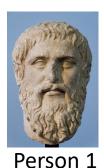
2. Wie werden Prozesse erzeugt? (Linux)

Ein Lebenszyklus eines Prozesses folgt einem Zustandsautomaten

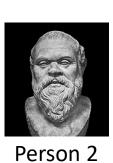


Warum überhaupt Synchronisieren?

Deadlocks





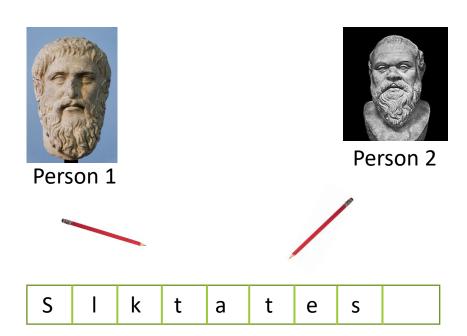


- Beide Personen möchten essen.
- Zum Essen benötigt jede Person zwei Gabeln.
- Sobald eine Person fertig ist legt sie die Gabeln zurück.

Falls beide Personen gleichzeitig ihre jeweils linke / rechte Gabel greifen wird nie gegessen!

1. Warum überhaupt Synchronisieren?

Korrupte Daten



- Jede Person will ihren Namen ins Textfeld schreiben.
- Jede Person prüft zuvor ob das Feld leer ist und schreibt dann hinein ohne erneut zu prüfen.

Falls beide Personen gleichzeitig prüfen so ist das Feld für sie leer. Selbst wenn die Personen abwechselnd schreiben so ist das Ergebnis nicht nutzbar!

2. Möglichkeiten zur Synchronisation

Deadlocks

```
int main(void)
  int err;
  srand(time(NULL));
  for(int i=0;i<2;i++)
    err = pthread create(&(tid[i]), NULL, &eat, (void*)i);
    if (err != 0)
       printf("\ncan't create thread :[%s]", strerror(err));
  pthread join(tid[0], NULL);
  pthread join(tid[1], NULL);
  return 0;
```

2. Möglichkeiten zur Synchronisation

Deadlocks

Ein Mutex ist eine Datenstruktur mit folgenden Eigenschaften:

- ,lock' sperrt einen Mutex, ,unlock' entsperrt diesen.
- ,lock' und ,unlock' sind atomar.
- Wird versucht ,lock" auf einem bereits gesperrten Mutex aufzurufen so wird an dieser Stelle gewartet bis der Mutex wieder entsperrt ist.

2. Möglichkeiten zur Synchronisation

Deadlocks

2. Möglichkeiten zur Synchronisation

Im Allgemeinen muss eine Lösung für den Zugriff auf kritische Blöcke folgende Bedingungen erfüllen:

Gegenseitiger Ausschluss:

Falls ein Prozess P den kritischen Bereich betreten hat so darf kein anderer Prozess diesen betreten.

• Fortschritt:

Falls kein Prozess den kritischen Bereich betreten hat aber weitere Prozesse diesen betreten möchten, so dürfen nur Prozesse außerhalb des Ausgangsbereich über den Eintritt entscheiden. Die Auswahl des Prozesses darf nicht unendlich lange dauern.

• <u>Endliches Warten</u>:

Falls ein Prozess den kritischen Bereich betreten hat und ein weiterer Prozess diesen betreten möchte so existiert ein Limit für die Anzahl wie oft er ausgewählt werden darf, nach dem Limit muss ein evtl. anderer wartender Prozess ausgewählt werden.

Nur ein Prozess im kritischen Bereich

Nur Prozesse vor dem kritischen Bereich dürfen mitentscheiden wer den kritischen Bereich betritt.

Ein Prozess darf nicht unendlich auf Eintritt warten.

Gegeben sind sind zwei Prozesse P0 und P1:

- i, j sind lokale int Variablen in P0 und P1
- P0 setzt i=0, j=1
- P1 setzt i=1, j=0
- Beide wollen den kritischen Abschnitt betreten.
- bool ready[2] ist eine globale Variable f
 ür beide Prozesse.
- int turn ist eine globale Variable für beide Prozesse.
- Zuweisungen für bool und int seien atomar.

<u>Aufgabe</u>: Prüfen Sie die Erfüllung von der Bedingung:

Nur ein Prozess im kritischen Bereich

Für den nebenstehenden Ansatz nach Peterson.

<u>Lösungshinweis</u>: Nehmen Sie an, dass beide Prozesse den kritischen

Abschnitt betreten haben und leiten Sie daraus einen Widerspruch ab.

```
//Eingangsbereich

ready[i] = TRUE;
turn = j;
while (ready[j] && turn == j);

//Kritischer Abschnitt

ready[i] = FALSE;

//Ausgangsbereich
```

<u>Aufgabe</u>: Angenommen P0 und P1 sind beide im kritischen Abschnitt.

Es gilt:

- Ein Prozess betritt den kritischen Abschnitt nur falls:
 - ready[j]==false oder turn==i
- → turn==0 für P0 und turn==1 für P1; das kann nicht sein
- es bleibt also nur ready[1] == ready[0] == false:
 - → da beide Prozesse noch im kritischen Abschnitt sind folgt, dass PO und P1 ready jeweils nicht auf TRUE gesetzt haben.

```
//Eingangsbereich
```

```
ready[i] = TRUE;
turn = j;
while (ready[j] && turn == j);
```

//Kritischer Abschnitt

ready[i] = FALSE;

//Ausgangsbereich

Geht es nicht auch mit einer Variable?

//Eingangsbereich

```
ready[i] = TRUE;
while (ready[j]);
```

//Kritischer Abschnitt

```
ready[i] = FALSE;
```

//Ausgangsbereich

Deadlock möglich da beide in Endlosschleife verbleiben falls ready[0/1] gleichzeitig auf TRUE gesetzt wurden

//Eingangsbereich

```
turn = j;
while (turn == j);
```

//Kritischer Abschnitt

```
turn = i;
```

//Ausgangsbereich

Falls P0 als erste dran kommt so hat P1 ihm dies erlaubt. Wenn P0 fertig ist so gibt er P1 den Zugriff auf den kritischen Abschnitt nicht frei, dies passiert erst wenn P0 erneut versucht den kritischen Abschnitt zu betreten.

Geht es nicht auch mit einer Variable? – Erneuter Versuch

```
//Eingangsbereich
```

```
turn = j;
while (turn == j);
```

//Kritischer Abschnitt

```
turn = j;
```

//Ausgangsbereich

Falls P0 als erste dran kommt so hat P1 ihm dies erlaubt. Wenn P0 fertig ist so gibt er P1 den Zugriff auf den kritischen Abschnitt frei; turn=1.

Falls P0 erneut den kritischen Abschnitt betreten möchte so setzt er turn=1 evtl. zum Zeitpunkt kurz nachdem P1 turn=0 gesetzt hat nachdem P1 fertig war. P0 wartet nun, falls P1 nie wieder versucht den kritischen Abschnitt zu betreten so wartet P0 unendlich lange. → Starvation (unendliches Warten auf eine Resource).

Falls PO als erste dran kommt so hat P1 ihm dies erlaubt.
Wenn PO fertig ist so gibt er P1 den Zugriff auf den
kritischen Abschnitt nicht frei, dies passiert erst wenn PO
erneut versucht den kritischen Abschnitt zu betreten.

Vielen Dank für die Aufmerksamkeit!



Sourcecode + Folien: https://github.com/dmalysiak/lecture fh muenster